

Билет_3_ОченьКратко

Вопрос 1: Цель хемоинформатики. Классификация методов по точности

Главная цель хемоинформатики — превращать химические данные в знание для поиска и оптимизации лекарств-кандидатов (lead compounds). Вычислительные методы делятся по точности и скорости:

1. **Квантовая химия (DFT/ab initio)** — самые точные, считают электронную структуру. Только для малых молекул, очень медленно.
2. **Силовые поля (молекулярная механика)** — атомы описываются классической физикой. Быстрее, применяются в молекулярной динамике.
3. **Дескрипторные методы (QSAR/QSPR)** — молекула кодируется числовым вектором. Очень быстро, миллионы молекул; основа машинного обучения.

По типу: **лиганд-базированные** (нет структуры белка — сравниваем молекулы) и **структурно-базированные** (есть 3D-структура — проводим докинг). Вторые точнее, но медленнее. На практике сначала быстрые фильтры, потом докинг кандидатов.

Вопрос 2: Метрики (Python) в хемоинформатике

Модели решают две задачи: **классификацию** (активная молекула или нет) и **регрессию** (предсказать числовое значение, например IC_{50}).

Метрики классификации:

- **ROC-AUC** (площадь под кривой ошибок) — 1.0 идеально, 0.5 — случайное угадывание. В Python: `sklearn.metrics.roc_auc_score`.
- **BEDROC** — метрика виртуального скрининга: насколько активные молекулы концентрируются в топе списка.
- **Матрица ошибок (Confusion Matrix)**: Precision, Recall (чувствительность), F1, Specificity.

Метрики регрессии:

- **RMSE** — корень из среднеквадратичной ошибки, насколько предсказание отличается от реальности.
- **R^2** — доля разброса данных, объяснённая моделью (1.0 = идеал).
- **Q^2** — R^2 на кросс-валидации; $Q^2 < R^2$ означает переобучение.

Стандарт: 80% обучение / 20% тест, 5-кратная кросс-валидация. Библиотеки: `sklearn` (метрики, алгоритмы), `RDKit` (дескрипторы и фингерпринты).

Вопрос 3: Преимущества и недостатки молекулярных скаффолдов

Скаффолд (scaffold — молекулярный каркас) — ядро структуры, общее для серии соединений.

Заместители варьируют для оптимизации активности.

Преимущества:

1. **Организация баз данных** — иерархическое дерево скаффолдов (Scaffold Tree) упрощает поиск по структурному родству.
2. **Репозиционирование лекарств** — поиск скаффолда среди одобренных препаратов FDA/EMA быстро даёт кандидатов для новых показаний.
3. **Генерация библиотек** — каркас + список заместителей → сотни производных для скрининга.
4. **Scaffold hopping** — замена ядра на аналог без токсичных фрагментов (токсикофоров) при сохранении активности.

Недостатки:

1. **Сужение химического пространства** — все производные похожи, трудно найти принципиально новые структуры.
2. **Синтетические ограничения** — многие виртуальные производные нельзя синтезировать.
3. **Наследование плохих свойств** — производные могут унаследовать высокий LogP или плохой метаболизм каркаса.

Статья: Shityakov & Förster (2014) — модель транспорта через ГЭБ

Зачем изучали: ~98% лекарств не проникают в мозг; нужен способ предсказать, какие молекулы доставит туда холиновый транспортёр ГЭБ (BBB-ChT — белок-переносчик холина через гематоэнцефалический барьер).

Как делали: BBB-ChT не имеет 3D-структуры — построили гомологичную модель по шаблону натрий/галактозного симпортера (PDB: 3DH4). Провели докинг (AutoDock и AutoDock Vina) 93 соединений; порог активности — $\Delta G_{\text{bind}} < -6.0$ ккал/моль.

Что получили: $r^2=0.88$ (предсказанные энергии vs эксперимент), AUC=0.82 — модель уверенно разделяет активные и неактивные молекулы. Артефакт: молекулы с <20 тяжёлыми атомами дают ложноотрицательный докинг.

Вывод: Гомологичная модель + докинг — рабочая альтернатива QSAR (предсказание активности по структуре) при отсутствии кристаллической структуры белка.

Связь с вопросами билета

Статья иллюстрирует структурно-базированный подход (Вопрос 1) и применение метрик AUC и r^2 для оценки модели (Вопрос 2); скаффолды бис-пиридиновых циклофанов служат примером целенаправленного использования молекулярного каркаса для ЦНС-доставки (Вопрос 3).