

Билет_17_ОченьКратко

Вопрос 1: Почему ретровирусные протеазы и циклодекстрины — предпочтительные модельные системы?

ВИЧ-протеаза используется как модель белок-лигандного взаимодействия по трём причинам:

1. Структура хорошо изучена — сотни кристаллических структур в базе PDB (база 3D-структур белков) с высоким разрешением ($\sim 2 \text{ \AA}$)
2. C2-симметрия (два одинаковых мономера) — удобно для тестирования алгоритмов докинга (виртуального «посадки» молекулы в активный сайт белка)
3. Известен референсный ингибитор Индинавир — есть эталон для сравнения расчётов

Циклодекстрины — циклические молекулы-«бочонки» из сахарных звеньев с гидрофобной полостью. β -циклодекстрин (7 звеньев) — наиболее удобен: полость чётко определена геометрически, хорошо изучена экспериментально. Это делает его стандартом для моделирования хозяин-гость взаимодействий (включение малой молекулы в полость). Обе системы — общепринятые бенчмарки для валидации методов молекулярного докинга и молекулярной динамики (симуляция движения атомов).

Вопрос 2: Какие молекулярные отпечатки используются в хемоинформатике?

Молекулярный отпечаток — цифровой «код» молекулы в виде строки из 0 и 1, где каждый бит означает наличие или отсутствие определённого структурного фрагмента. Используются для поиска похожих молекул и как входные данные для машинного обучения.

Основные типы:

1. **ECFP** (Extended Connectivity Fingerprint, круговые) — кодируют атомное окружение на заданном радиусе; ECFP4 наиболее популярны для предсказания биологической активности
2. **MACCS keys** — 166 фиксированных фрагментов; простые и интерпретируемые
3. **Avalon / Daylight / RDKit** — топологические: кодируют пути между атомами в молекуле
4. **Фрагментные (RDKit)** — при сочетании с XGBoost (алгоритм машинного обучения) дают AUC ROC ≈ 0.96 для предсказания проницаемости через ГЭБ (гематоэнцефалический барьер)

Главная метрика сходства — коэффициент Танимото: $T = \text{общие биты} / (\text{сумма всех бит A и B минус общие})$.

Вопрос 3: Чем отпечатки отличаются от молекулярных дескрипторов?

Молекулярный дескриптор — числовое значение физико-химического свойства: LogP (липофильность), PSA (полярная площадь поверхности), молекулярная масса и др. Дескрипторы непрерывные (например,

$\text{LogP} = 2.3$), их может быть более 5000.

Фингерпринт — специальный подтип дескриптора в виде битового вектора: дискретный (0 или 1), кодирует структурные фрагменты, а не физические свойства.

Ключевые различия:

- Дескрипторы → непрерывные числа → QSAR (метод предсказания активности молекул по их структуре) и регрессия
- Фингерпринты → биты → поиск сходства и классификация
- Дескрипторы интерпретируемы; фингерпринты — часто «чёрный ящик»

На практике лучшие модели используют оба типа вместе.

Статья: Shityakov et al. (2020) — Виртуальное секвенирование ДНК-плазмид

Зачем изучали: Проверить, может ли алгоритм имитировать shotgun-секвенирование (дробовиковое — случайное дробление ДНК на фрагменты с последующей сборкой) до реального эксперимента.

Как делали: Три плазмиды (2319–4886 пн) «секвенировали» виртуально (алгоритм Sequencer + TIGR Assembler) при длинах фрагментов 100, 400, 800 нт и покрытии 1–9; затем валидировали ПЦР (лабораторный метод копирования ДНК).

Что получили: При длине ≥ 400 нт и покрытии ≥ 4 — один непрерывный контиг (собранная последовательность), зависимость линейная ($r^2=0.99$). ПЦР подтвердила расчёты: $r^2=0.92$, $p=0.012$.

Вывод: Алгоритм работает как дешёвый инструмент контроля качества и планирования реального секвенирования.

Связь с вопросами билета

Статья иллюстрирует ключевой принцип курса: вычислительная модель предшествует эксперименту — та же логика, что в молекулярном докинге и QSAR.