

Хемоинформатика

Билеты к экзамену

Очень кратко

Все 17 билетов в одном документе

ИТМО

2026

Содержание

1	Определение хемоинформатики и области применения	4
1.1	Вопрос 1: Определение хемоинформатики и области применения	4
1.2	Вопрос 2: Отличие хемоинформатики от биоинформатики	4
1.3	Вопрос 3: Стандартный пайплайн в хемоинформатике	4
1.4	Статья: Shityakov & Dandekar (2010) — виртуальный скрининг ингибиторов ВИЧ-протеазы	5
2	In silico методы, ГЭБ и экспериментальные данные	6
2.1	Вопрос 1: Два основных in silico метода в хемоинформатике	6
2.2	Вопрос 2: Почему ГЭБ критически важен для хемоинформатики?	6
2.3	Вопрос 3: Как хемоинформатика использует экспериментальные данные для обучения?	6
2.4	Статья: Дескрипторы полярной поверхности и проницаемость ГЭБ	7
3	Химическое пространство, метрики и скаффолды	8
3.1	Вопрос 1: Цель хемоинформатики. Классификация методов по точности	8
3.2	Вопрос 2: Метрики в хемоинформатике	8
3.3	Вопрос 3: Преимущества и недостатки молекулярных скаффолдов	8
3.4	Статья: Shityakov & Förster (2014) — модель транспорта через ГЭБ	9
4	Фармакофор и молекулярный докинг	10
4.1	Вопрос 1: Концепция фармакофора. Типы фармакофоров.	10
4.2	Вопрос 2: Молекулярный докинг. Типы молекулярного докинга.	10
4.3	Вопрос 3: Программное обеспечение для молекулярного докинга.	11
4.4	Статья: Shityakov et al. 2014 — cRPT ВИЧ-1 в пенистых вирусных векторах	11
5	Алгоритмы докинга и машинное обучение	12
5.1	Вопрос 1: Алгоритмы молекулярного докинга	12
5.2	Вопрос 2: Принципы машинного обучения в хемоинформатике	12
5.3	Вопрос 3: Недостатки генетических алгоритмов в молекулярном докинге	13
5.4	Статья: Scaffold Searching in Alzheimer’s Disease (Shityakov et al., 2021)	13
6	Белки-мишени, сайты связывания, ошибка докинга	14
6.1	Вопрос 1: Какие белки предпочтительны для молекулярного докинга?	14
6.2	Вопрос 2: Стандартная ошибка для наибольшего кластера. Как минимизировать?	14
6.3	Вопрос 3: Типы сайтов связывания и их влияние на докинг	14
6.4	Статья: Fareed 2022 — SNP в β -дефенсине-1	14
7	Белок-белковый докинг и молекулярная динамика	16
7.1	Вопрос 1: Алгоритмы белок-белкового докинга. Отличия от белок-лигандного	16
7.2	Вопрос 2: Молекулярная динамика — типы, важность, плюсы и минусы	16
7.3	Вопрос 3: Химические расчёты в рациональном дизайне лекарств	16
7.4	Статья: Kovalenko et al. 2023 — клик-химия для ингибиторов D3R	17

8 ПО для молекулярной динамики	18
8.1 Вопрос 1: ПО для молекулярной динамики и примеры применения	18
8.2 Вопрос 2: Силовые поля в МД: типы, плюсы и минусы	18
8.3 Вопрос 3: Ключевые параметры МД для оценки белка	19
8.4 Статья: Ergodicity Breaking and Self-Destruction of Cancer Cells	19
9 Вычислительная синтетическая биология и QSAR	20
9.1 Вопрос 1: Вычислительная синтетическая биология и хемоинформатика . .	20
9.2 Вопрос 2: Теория графов в синтетической биологии и хемоинформатике . .	20
9.3 Вопрос 3: QSAR и QSPR — концепция и типы	20
9.4 Статья: NeuroClick (Isakova et al., 2024)	21
10 Монте-Карло, Drug Repurposing, базы данных	22
10.1 Вопрос 1: Монте-Карло и имитация отжига	22
10.2 Вопрос 2: Drug repurposing	22
10.3 Вопрос 3: Химические базы данных	22
10.4 Статья: Dutta et al. 2024 — SNP в hnRNP A2/B1	23
11 Молекулярные дескрипторы и химические форматы	24
11.1 Вопрос 1: Молекулярный дескриптор — что это и какие важны для ГЭБ? .	24
11.2 Вопрос 2: Типичные химические форматы в хемоинформатике	24
11.3 Вопрос 3: Основные дескрипторы в QSAR/QSPR	24
11.4 Статья: Вороной-энтропия как дескриптор лиганд-белок взаимодействий . .	25
12 Сворачивание белка и секвенирование	26
12.1 Вопрос 1: Сворачивание белка и его значение для хемоинформатики	26
12.2 Вопрос 2: ПЦР и in silico методы; сайт-направленный мутагенез	26
12.3 Вопрос 3: Методы секвенирования; анализ экспрессии генов	26
12.4 Статья: Топологический биоскейлинг как мера сворачивания белков	27
13 Моделирование реакций и алгоритмы фолдинга	28
13.1 Вопрос 1: Моделирование химических реакций in silico	28
13.2 Вопрос 2: Хемоинформатика в генераторах химических реакций	28
13.3 Вопрос 3: Алгоритмы анализа молекулярного фолдинга	28
13.4 Статья: RetroFold — асимметрия фолдинга белка	29
14 ML/DL и конформационный поиск	30
14.1 Вопрос 1: ML/DL методы в хемоинформатике	30
14.2 Вопрос 2: ML/DL vs классические методы	30
14.3 Вопрос 3: Конформационный поиск, симметрия, тесселяция Вороного . . .	31
14.4 Статья: α -Циклодекстриновый димер для доставки дофамина в мозг	31
15 Хемоинформатика в материаловедении. Протокол МД	32
15.1 Вопрос 1: Хемоинформатика в материаловедении и супрамолекулярной химии	32
15.2 Вопрос 2: Стандартный протокол молекулярной динамики	32
15.3 Вопрос 3: Стандартный протокол молекулярного докинга (AutoDock Vina) .	32
15.4 Статья: Shityakov & Förster (2013) — P-gr с фуллеренами и нанотрубкой . .	32

16 ADME/ADMET	34
16.1 Вопрос 1: Концепция ADME/ADMET в хемоинформатике	34
16.2 Вопрос 2: Молекулярные дескрипторы для расчёта ADME-свойств	34
16.3 Вопрос 3: Метод scaffold hopping в хемоинформатике	34
16.4 Статья: Tamaian et al. (2023) — Новые антипсихотики с улучшенным профилем	35
17 Ретровирусные протеазы и фингерпринты	36
17.1 Вопрос 1: Почему ретровирусные протеазы и циклодекстрины — предпочти- тельные модельные системы?	36
17.2 Вопрос 2: Молекулярные фингерпринты в хемоинформатике	36
17.3 Вопрос 3: Чем фингерпринты отличаются от молекулярных дескрипторов? .	36
17.4 Статья: Shityakov et al. (2020) — Виртуальное секвенирование ДНК-плазмид	37
Краткая таблица: ключевые статьи	38
Главные формулы	39

Билет 1. Определение хемоинформатики и области применения

1.1 Вопрос 1: Определение хемоинформатики и области применения

Хемоинформатика — наука на стыке химии, математики и информатики для анализа химической информации. Определения вводились постепенно:

- **Структурное** (G. Paris, 1998): дизайн, организация, визуализация хим. информации
- **Прагматическое** (F.K. Brown, 1998): данные → информация → знание → лучшие решения быстрее (ключевая формула)
- **Лаконичное** (J. Gasteiger, 2004): методы информатики для решения хим. задач
- **Математическое** (A. Varnek & I. Baskin, 2011): молекула = объект (граф или вектор) в **химическом пространстве**: каждая молекула — точка, её координаты — свойства (*дескрипторы*); представления: 1D-строки (SMILES), 2D-графы, 3D-структуры (PDB, SDF)

Области применения:

1. Виртуальный скрининг — поиск кандидатов в лекарства без синтеза
2. Рациональный дизайн лекарств — цикл хит → лид → кандидат (**Хит** — нашли активную молекулу; **Лид** — улучшили молекулу; **Кандидат** — выбрали лучшую версию для клинических исследований)
3. Молекулярный докинг — предсказание связывания молекулы с белком
4. QSAR/QSPR (количественные зависимости структура–активность/свойства)
5. ADME/Tox — предсказание всасывания, распределения, метаболизма, токсичности
6. Перепрофилирование препаратов (*drug repurposing*)

1.2 Вопрос 2: Отличие хемоинформатики от биоинформатики

Обе области используют вычислительные методы и машинное обучение, но работают с разными объектами:

- **Хемоинформатика** изучает **малые органические молекулы**: структуры, дескрипторы (числовые характеристики молекулы), взаимодействия с белками. Задачи: виртуальный скрининг, QSAR, молекулярный докинг.
- **Биоинформатика** работает с **крупными биологическими данными**: геномными последовательностями, структурами белков. Задачи: секвенирование ДНК, предсказание структур белков (AlphaFold), анализ экспрессии генов.

Пересечение: предсказание белок-лигандных взаимодействий требует обоих подходов — хемоинформатика даёт молекулу, биоинформатика — белок.

1.3 Вопрос 3: Стандартный пайплайн в хемоинформатике

Пайплайн — воронка для химического пространства: от миллионов молекул к одному лекарственному кандидату.

1. **База данных** — PubChem, ChEMBL, ZINC содержат от 10^9 до 10^{14} молекул
2. **Фильтрация** — отсев «плохих» молекул по **правилу Липинского**: $MW \leq 500$ Da, $\log P \leq 5$, Н-доноры ≤ 5 , Н-акцепторы ≤ 10 ; также TPSA и структурные алерты

3. **Виртуальный скрининг** двух типов:

- *Structure-based*: молекулярный докинг в активный сайт белка
- *Ligand-based*: поиск по сходству с известной активной молекулой

4. **Hit identification** — отбор кандидатов по скоринговым функциям + кластеризация5. **In vitro / in vivo валидация** — синтез и проверка6. **Оптимизация Hit** → **Lead**: улучшают активность, селективность, ADME, убирают токсичные фрагменты7. **Lead optimization** — доработка до кандидата (фармакокинетика, биодоступность)8. **Candidate** — Lead, прошедший все критерии. Готов к клиническим испытаниям (фазы I → II → III).

1.4 Статья: Shityakov & Dandekar (2010) — виртуальный скрининг ингибиторов ВИЧ-протеазы

Зачем изучали: Найти новые ингибиторы ВИЧ-1 протеазы, обходящие мутационную резистентность к существующим препаратам.

Как делали: Взяли индинавир (IDV) и с помощью генетического алгоритма сгенерировали 1300 производных, затем воронка: отбор по форме → фармакофорный фильтр → правило Lipinski → молекулярный докинг (Molegro, AutoDock) → оценка токсичности (ADME/Tox).

Что получили: Из 1300 остался 1 хит с MW = 494.6 Da. Образует 10 водородных связей с протеазой (IDV — 9), минимальная энергия связывания −13.8 против −15.1 ккал/моль у IDV.

Вывод: Комбинированный виртуальный скрининг позволяет находить молекулы с новым механизмом связывания и лучшим лекарственным профилем.

Связь с вопросами билета

Статья — прямая иллюстрация стандартного хемоинформатического пайплайна (вопрос 3): воронка из 1300 соединений до 1 хита. Применённый метод lead expansion и фармакофорный скоринг показывают, как хемоинформатика решает задачи рационального дизайна лекарств (вопрос 1) с инструментарием, недоступным чистой биоинформатике (вопрос 2).

Билет 2. In silico методы, ГЭБ и экспериментальные данные

2.1 Вопрос 1: Два основных in silico метода в хемоинформатике

В хемоинформатике два подхода к виртуальному скринингу:

1. **Ligand-based** — структуру белка не знаем, работаем от активных молекул. Методы:
 - Фильтры по физ.-хим. свойствам (правило Липинского)
 - Поиск по similarity
 - **Фармакофорное моделирование** — определение ключевых пространственных и эл.-хим. характеристик → предсказание активности
 - **QSAR-моделирование**: молекула → дескрипторы → модель → предсказание активности
2. **Structure-based** — знаем структуру белка → молекулярный докинг. В VS последовательно: ligand-based → structure-based (воронка: миллионы → тысячи → единицы хитов).

2.2 Вопрос 2: Почему ГЭБ критически важен для хемоинформатики?

ГЭБ (гематоэнцефалический барьер) — защитная стенка между кровью и мозгом. Через него не проникает 98% потенциальных лекарств.

- Для препаратов против болезней Альцгеймера, Паркинсона, опухолей мозга — проникновение **обязательно**.
- Для периферических препаратов — проникновение **нежелательно** (нейротоксичность).

Хемоинформатика решает это с помощью:

- Дескрипторов: $TPSA < 60-70 \text{ \AA}^2$, LogP , $MW < 500 \text{ Da}$
- Параметра $\log BB = \log(\text{концентрация в мозге} / \text{концентрация в крови})$ — **главный параметр проницаемости через ГЭБ**
- Машинного обучения (Random Forest, нейросети)

Пример QSAR — метод Кларка:

$$\log BB = 0.152 \cdot \log P - 0.0148 \cdot TPSA + 0.139$$

Важно учитывать Р-гликопротеин (P-gp) — белок-«насос», который выкачивает молекулы обратно из мозга.

2.3 Вопрос 3: Как хемоинформатика использует экспериментальные данные для обучения?

Модели в хемоинформатике невозможны без экспериментальных данных.

Два направления:

1. **Индуктивное** (Данные → Знание): обучаем модель на экспериментальных IC_{50} , $\log BB$, K_i → модель предсказывает свойства новых молекул. Пример: **QSAR** и метод Кларка ($\log BB$).

2. **Дедуктивное** (Знание $\rightarrow$ Данные): знаем механизм $\rightarrow$ генерируем подходящие соединения. Пример: **NeuroClick** — знаем механизм клик-реакции $\rightarrow$ генерируем молекулы.

Валидация: разбивка 80/20, кросс-валидация, метрики R^2 и RMSE. Цикл «данные $\rightarrow$ модель $\rightarrow$ предсказание $\rightarrow$ эксперимент $\rightarrow$ уточнение» — основа рационального дизайна лекарств.

2.4 Статья: Дескрипторы полярной поверхности и проницаемость ГЭБ

Зачем изучали: Выяснить, какой дескриптор PSA лучше всего предсказывает проникновение через ГЭБ.

Как делали: Сравнили три дескриптора — 2D-PSA, TPSA и 3D-PSA (квантово-механический метод DFT) — на 19 препаратах; сопоставили с экспериментальными logBB через PLS-регрессию.

Что получили: 3D-PSA — лучший результат ($R^2 = 0.92$, RMSD = 0.29); TPSA чуть хуже ($R^2 = 0.85$), но рассчитывается быстрее. Порог: $PSA < 60 \text{ \AA}^2$ — молекула проникает через ГЭБ. Выбросы (risperidone, domperidone) — субстраты P-gr.

Вывод: TPSA — оптимальный дескриптор для быстрого скрининга; 3D-PSA точнее, но дороже; модели пассивной диффузии не работают при наличии P-gr.

Связь с вопросами билета

Статья — прямой пример ligand-based подхода (вопрос 1): дескрипторы PSA используются как фильтры. Одновременно показывает, как экспериментальные logBB служат основой для обучения регрессионной модели (вопрос 3) и почему ГЭБ — центральная тема хемоинформатики (вопрос 2).

Билет 3. Химическое пространство, метрики и скаффолды

3.1 Вопрос 1: Цель хемоинформатики. Классификация методов по точности

Цель хемоинформатики — сузить химическое пространство от $\sim 10^{60}$ возможных молекул до нескольких кандидатов.

Химическое пространство: Берёшь молекулу $\rightarrow$ считаешь N дескрипторов (MW, logP, TPSA, ...) $\rightarrow$ получаешь вектор из N чисел $\rightarrow$ координаты точки в N -мерном пространстве. Расстояние между точками = мера похожести:

$$d = \sqrt{(500 - 480)^2 + (3.2 - 2.8)^2 + (120 - 115)^2 + \dots}$$

Обязательна **нормализация** дескрипторов (разные единицы и масштабы).

Вычислительные методы по точности (убывание) и скорости (возрастание):

1. **DFT (квантовая химия)** — самые точные, считают электронную структуру. Только для малых молекул, очень медленно.
2. **Силовые поля (классическая механика)** — потенциалы Леннарда-Джонса. Применяются в молекулярной динамике.
3. **Дескрипторы + ML/DL:** классический ML, Random Forest, GNN, нейросети.

3.2 Вопрос 2: Метрики в хемоинформатике

Модели решают две задачи: **классификацию** и **регрессию**.

Метрики классификации:

- **ROC-AUC** — площадь под кривой ошибок; 1.0 идеально, 0.5 — случайное угадывание.
- **BEDROC** — модификация ROC-AUC: штраф, если активные молекулы в конце списка.
- **EF (Enrichment Factor)** — доля активных молекул в топ $X\%$ списка.
- **Precision, Recall, F_1**

Метрики регрессии:

- **RMSE** — среднеквадратичная ошибка
- **R^2** — доля объяснённого разброса (1.0 = идеал)
- **Q^2 - R^2 :** $Q^2 = R^2$ на кросс-валидации; разрыв $Q^2 \ll R^2$ означает переобучение

Стандарт: 80% обучение / 20% тест, 5-кратная кросс-валидация. Библиотеки: `sklearn`, `RDKit`.

3.3 Вопрос 3: Преимущества и недостатки молекулярных скаффолдов

Скаффолд (scaffold) — общее ядро структуры для серии соединений. Заместители варьируют для оптимизации активности.

Задачи со скаффолдами:

- **Scaffold Hopping** — меняется каркас, но сохраняется биоактивность $\rightarrow$ расширение хим. пространства

- **Scaffold Diversity** — максимально разные каркасы в коллекции
- **Scaffold Murcko** — метод в RDKit для извлечения каркаса из молекулы

Плюсы: организация БД, репозиционирование препаратов, генерация библиотек.

Минусы: сужение хим. пространства, синтетические ограничения, наследование плохих свойств каркаса.

3.4 Статья: Shityakov & Förster (2014) — модель транспорта через ГЭБ

Зачем изучали: ~98% лекарств не проникают в мозг; нужен способ предсказать, какие молекулы доставит туда холиновый транспортёр ГЭБ (BBB-ChT).

Как делали: BBB-ChT не имеет 3D-структуры — построили гомологичную модель по шаблону натрий/галактозного симпортера (PDB: 3DH4). Провели докинг (AutoDock и AutoDock Vina) 93 соединений; порог активности — $\Delta G_{bind} < -6.0$ ккал/моль.

Что получили: $r^2 = 0.88$, $AUC = 0.82$. Артефакт: молекулы с <20 тяжёлыми атомами дают ложноотрицательный докинг.

Вывод: Гомологичная модель + докинг — рабочая альтернатива QSAR при отсутствии кристаллической структуры белка.

Связь с вопросами билета

Статья иллюстрирует структурно-базированный подход (вопрос 1) и применение метрик AUC и r^2 для оценки модели (вопрос 2); скаффолды бис-пиридиновых циклофанов служат примером целенаправленного использования молекулярного каркаса для ЦНС-доставки (вопрос 3).

Билет 4. Фармакофор и молекулярный докинг

4.1 Вопрос 1: Концепция фармакофора. Типы фармакофоров.

Фармакофор — абстрактная 3D-модель того, какие хим. группы и где именно в пространстве должны быть у молекулы, чтобы она связалась с белком. Это **не конкретная молекула, а шаблон требований**.

Плюсы:

- Ligand-based — без структуры белка
- Быстрый скрининг (проверка на соответствие, не докинг)
- Объясняет, почему структурно разные молекулы активны
- Различает близкородственные мишени (D2/D3 дофамина, 78% идентичность)

Минусы:

- Не учитывает гибкость белка
- Не учитывает сольватацию
- Требуется набор известных активных молекул

Типы:

1. Признаковые (feature-based) — набор конкретных химических групп
2. Нечёткие (fuzzy) — учитывают пространственную неопределённость
3. Лиганд-ориентированные — из анализа активных молекул
4. Структурно-ориентированные — из 3D-структуры сайта связывания белка
5. Полевые (field-based) — используются в CoMFA/CoMSIA-анализе

4.2 Вопрос 2: Молекулярный докинг. Типы молекулярного докинга.

Молекулярный докинг — вычисление аффинности связывания рецептора и лиганда. Алгоритм перебирает конформации лиганда в сайте связывания и ищет позу с минимальной свободной энергией Гиббса (ΔG).

Типы по гибкости системы:

1. Жёсткий рецептор / гибкий лиганд (rigid-flexible) — стандарт, быстрый
2. Оба гибкие (flexible-flexible) — реалистичнее, вычислительно дорог
3. Оба жёсткие (rigid-rigid) — геометрическое сопоставление поверхностей
4. Избирательная гибкость — гибкие только отдельные остатки рецептора

Ключевые ограничения: рецептор считается жёстким, вода в сайте не учитывается, стандартная ошибка до 1.5 ккал/моль.

Скоринговая функция — оценка выгодности позы лиганда (ккал/моль). **4 класса:**

Класс	Суть	Применение
Силовые поля (FF)	$E_{VDW} + E_{elec}$ (Леннард-Джонс + Кулон)	AutoDock 4
Knowledge-based	Статистика межмолекулярных контактов из PDB	PMF-score, DrugScore
Эмпирические	Взвешенная сумма типов взаимодействий	AutoDock Vina, GlideScore

Класс	Суть	Применение
Гибридные	FF + эмпирика; $\Delta G = \Delta H - T\Delta S$	ММ-PBSA/ММ-GBSA

$\Delta G < -8$ ккал/моль — хорошее связывание; связь с K_i : $\Delta G = RT \cdot \ln(K_i)$.

4.3 Вопрос 3: Программное обеспечение для молекулярного докин-га.

ПО	Алгоритм	Скоринг	Плюсы	Минусы
AutoDock 4	Генетический алгоритм + Монте-Карло	Силовые поля; медленный	Эталон, цитируется	Bias для малых молекул
AutoDock Vina	BFGS локальный поиск	Эмпирический; быстрый	Прост, многопоток	Тот же bias
Glide (Schrödinger)	Иерархический + refinement	GlideScore; средний	Высокая точность	Дорого
GOLD (CCDC)	Генетический	Эмпирический + H-bond; медленный	Учитывает воду	Медленнее Vina
PatchDock	Геометр. хэширование	Геометрический; быстрый	Белок-белковый	Нативная конформация редко в топе
DiffDock (MIT, 2022)	Обратная диффузия (ML)	Confidence-модель	RMSD <2 Å в >38%	Нет физической функции
GNINA	Монте-Карло + CNN	CNN; средний	+5% vs AutoDock	Требуется GPU

4.4 Статья: Shityakov et al. 2014 — сРРТ ВИЧ-1 в пенистых вирусных векторах

Зачем изучали: Проверить, позволит ли перенос сРРТ из ВИЧ-1 в пенистовирусный (FV) вектор трансдуцировать неделящиеся клетки.

Как делали: Клетки A549 останавливали афидиколином в фазе G1/S, заражали четырьмя конструктами, эффективность оценивали по eGFP (проточная цитометрия); логистическая доза-ответ модель (MATLAB) верифицировала данные.

Что получили: FV-вектор с сРРТ ВИЧ-1 дал трансдукцию в 20 раз ниже лентивирусного контроля. Причина — обратная транскриптаза FV не распознаёт чужеродный элемент ВИЧ-1.

Вывод: сРРТ ВИЧ-1 не функционален в FV-контексте; для неделящихся клеток нужны лентивирусные векторы.

Билет 5. Алгоритмы докинга и машинное обучение

5.1 Вопрос 1: Алгоритмы молекулярного докинга

Генетический алгоритм (GA) — AutoDock 4

Особь = поза лиганда, **фитнес** = значение скоринговой функции. Алгоритм — одно поколение:

1. **Инициализация** — генерация случайных поз (например, 100 поз)
2. **Оценка** — score для каждой позы
3. **Отбор** — лучшие позы выживают
4. **Скращивание** — 2 позы объединяют часть генов → новая поза (каждый параметр выбирается случайно)
5. **Мутация** — случайное изменение 1 параметра позы
6. **Оценка score** → **Отбор**

Стоп: достигнуто max число поколений ИЛИ score перестал улучшаться.

Монте-Карло (MC)

1. Score для нач. позы лиганда
2. Случайно сдвинуть 1 параметр → новая поза + новый score
3. Решение: а) новый score лучше → принять; б) хуже → принять с вероятностью $\exp(-\Delta E/kT)$ (**критерий Метрополиса**)
4. Повторить до конца

Имитация отжига (SA, Simulated Annealing)

Расширение MC: та же идея, но температура T постепенно снижается по расписанию $T = T_0 \cdot \alpha^{\text{шаг}}$, например $\alpha = 0.99$.

При высокой T : $\exp(-\Delta E/kT) \approx 1 \rightarrow$ плохие ходы часто принимаются (широкий поиск). При низкой T : $\rightarrow 0 \rightarrow$ локальная оптимизация.

ML-методы в докинге: DiffDock (генеративная диффузия), EquiBind/TankBind (регрессия координат), GNINA (MC + CNN, +5% vs AutoDock).

5.2 Вопрос 2: Принципы машинного обучения в хемоинформатике

1. Представление молекулы:

- **Дескрипторы** — числовые свойства: MW, logP, TPSA, ... → вектор
- **Fingerprints (ECFP)** — битовый вектор наличия структурных фрагментов
- **Граф** — атомы = узлы, связи = рёбра; для GNN

2. Типы задач:

- **Классификация** — активная молекула или нет? Метрики: ROC-AUC, F_1 , BEDROC
- **Регрессия** — предсказать числовое значение (IC_{50} , logBB, ΔG). Метрики: RMSE, R^2
- **Генерация** — создать новые молекулы (VAE, GAN, диффузия)

3. Ключевые принципы:

- **Переобучение:** Q^2 на кросс-валидации должен быть близок к R^2

- **Домен применимости:** модель надёжна только для молекул, похожих на обучающую выборку
- **Несбалансированность классов:** активных молекул обычно $\ll$ неактивных $\rightarrow$ нужна BEDROC/EF вместо ассигасы

5.3 Вопрос 3: Недостатки генетических алгоритмов в молекулярном докинге

1. **Жёсткий рецептор:** induced-fit не учитывается
2. **Ограниченное пространство поиска:** нужна сетка $\leq 60 \text{ \AA}$; blind docking неэффективен
3. **Size-related bias:** малые молекулы недооцениваются, крупные переоцениваются
4. **Экспоненциальный рост:** каждая вращаемая связь умножает число конформаций
5. **Риск застревания** в локальном минимуме при малом числе итераций
6. **Нет параметров:** если для атомов лиганда нет параметров в силовом поле — докинг невозможен

5.4 Статья: Scaffold Searching in Alzheimer's Disease (Shityakov et al., 2021)

Зачем: Найти одобренные препараты с активностью против β -амилоидного пептида ($A\beta$) при болезни Альцгеймера (drug repurposing).

Как делали: В DrugCentral (4642 препарата) провели скаффолд-поиск по структуре трамипросата (TRA); 13 хитов проверили докингом (AutoDock 4) к $A\beta$ -фибриллам (PDB: 2NAO), стабильность подтвердили 100 нс МД (MM-GBSA).

Что получили: Менадион бисульфит ($\Delta G = -7.11$ ккал/моль) и камфотамид ($\Delta G = -6.82$) превзошли TRA ($\Delta G = -6.19$). MM-GBSA: менадион $\Delta G_{GB} = -19.71$, TRA = -10.1 ккал/моль.

Вывод: Скаффолд-поиск $\rightarrow$ докинг $\rightarrow$ МД — рабочий in silico пайплайн.

Билет 6. Белки-мишени, сайты связывания, ошибка докинга

6.1 Вопрос 1: Какие белки предпочтительны для молекулярного докинга?

Для докинга берут белки с **известной 3D-структурой** (рентгеновская кристаллография или ЯМР). Идеальный белок содержит **ко-кристаллизованный лиганд** — это позволяет проверить метод: повторный докинг должен воспроизвести позу с $\text{RMSD} < 2 \text{ \AA}$.

Основные категории мишеней:

- **Вирусные/бактериальные:** HIV-1 протеаза (Asp25), главная протеаза SARS-CoV-2 (Mpro), β -дефенсин-1 (DEFB1)
- **ЦНС:** дофаминовые рецепторы D2/D3, серотониновые рецепторы
- **Онкологические:** Bcl-2, амилоид- β

Если кристаллической структуры нет — строят **гомологичную модель** (SWISS-MODEL, Modeller). Качество оценивают через **диаграмму Рамачандрана** ($\geq 90\%$ остатков в допустимых зонах).

6.2 Вопрос 2: Стандартная ошибка для наибольшего кластера. Как минимизировать?

Ошибка в расчёте ΔG составляет ± 1.5 ккал/моль. Как уменьшить:

1. Увеличить число рангов (до 100), повысить **exhaustiveness** до 16–32 в AutoDock Vina
2. Добавить водороды, рассчитать заряды Гастайгера, использовать **holo-форму**
3. Пост-докинг-рескоринг: MM-PBSA/MM-GBSA по данным МД
4. ML-подходы: DiffDock — $\text{RMSD} < 2 \text{ \AA}$ в 38% случаев

6.3 Вопрос 3: Типы сайтов связывания и их влияние на докинг

- **Активный (каталитический)** — место реакции. Пример: Asp25 в HIV-1 протеазе. Координаты известны $\rightarrow$ точный grid box.
- **Ортостерический** — совпадает с сайтом природного лиганда.
- **Алlostерический** — удалён от активного сайта; лиганд косвенно меняет конформацию белка. Нужен слепой докинг. Инструмент: PatchDock.
- **Криптический** — появляется при мутациях или конформационных изменениях. Инструменты: CAVER, PocketAnalyzerPCA.

6.4 Статья: Fareed 2022 — SNP в β -дефенсине-1

Зачем: Выяснить, какие nsSNP в гене DEFB1 нарушают антимикробную функцию β -дефенсина-1.

Как делали: 4 инструмента патогенности (SIFT, PolyPhen-v2, PROVEAN, Snps&GO) $\rightarrow$ докинг AutoDock $\rightarrow$ МД 100 нс (AMBER 16) с рескорингом MM-PBSA/GBSA.

Что получили: Из всех nsSNP четыре делетерийных: C67S, T58S, G62W, Y35C. Только **T58S и Y35C** разрушают сайт связывания RIP2.

Вывод: T58S и Y35C — потенциальные биомаркеры восприимчивости к инфекциям.

Связь с вопросами билета

Статья иллюстрирует все три вопроса: DEFB1 — пример белка-мишени для докинга, MM-PBSA/GBSA показывает метод снижения ошибки, а T58S/Y35C — пример того, как мутация в активном сайте нарушает функцию белка.

Билет 7. Белок-белковый докинг и молекулярная динамика

7.1 Вопрос 1: Алгоритмы белок-белкового докинга. Отличия от белок-лигандного

Белок-белковый докинг (**PPI**) предсказывает, как два крупных белка стыкуются. Поиск идёт по всей поверхности.

1. **FFT (быстрое преобразование Фурье)** — ZDOCK, ClusPro. За одно вычисление оценивает все положения. Быстро, но без гибкости.
2. **HADDOCK** — использует экспериментальные ограничения (NMR, мутагенез). Стадии: жёсткий докинг → гибкое уточнение → вода. Наиболее точный.
3. **RosettaDock** — Монте-Карло с перебором боковых цепей на интерфейсе.

Ключевые отличия: лиганд ~ 70 атомов vs белок $\sim$ тысячи остатков; поиск в кармане $20 \text{ \AA}$ vs вся поверхность; минуты CPU vs часы на кластере.

7.2 Вопрос 2: Молекулярная динамика — типы, важность, плюсы и минусы

МД — симуляция движения атомов: для каждого атома на каждом шаге (~ 2 фс) решается $F = ma$. Алгоритм Верле/leap-frog:

$$F = -\frac{dU}{dr}, \quad a = F/m, \quad v(t + dt) = v(t) + a \cdot dt, \quad r(t + dt) = r(t) + v \cdot dt$$

Зачем МД после докинга? Докинг — статичная «фотография»; МД — «видео»: проверяет стабильность комплекса, учитывает гибкость белка, растворитель и энтропию, даёт более точную ΔG .

Тип	Масштаб	Когда применять	Особенность
Классическая (MM)	фс–мкс	Белок-лиганд, мембраны	AMBER, CHARMM
Ab initio / QM	пс, $\leq$ сотни атомов	Хим. реакции, разрыв связей	DFT
QM/MM	нс, тысячи атомов	Ферментативные реакции	Активный сайт — квантово
Coarse-grained	мкс–мс	Сворачивание белка	Группы атомов = «бусина»

Плюсы: детализация динамики, количественный ΔG , учёт гибкости белка.

Минусы: требует GPU/кластер; «застревание» в локальных минимумах; классическая МД не описывает разрыв связей.

7.3 Вопрос 3: Химические расчёты в рациональном дизайне лекарств

Три уровня:

1. **Квантовая химия (DFT)** — карты электростатического потенциала, 3D-PSA. Только для малых молекул.
2. **Докинг и МД** — аффинность связывания и динамическая стабильность комплекса.
3. **ADME-фильтры:**
 - Правило Липинского: $MW < 500$ Da, $\log P < 5$, $HBD \leq 5$, $HBA \leq 10$
 - $\log BB$ (ГЭБ): $\log BB = 0.152 \cdot ClogP - 0.0148 \cdot TPSA + 0.139$; порог ≥ 0.3
 - $TPSA$ — дескриптор, коррелирующий с всасыванием

QSAR — модель, связывающая дескрипторы с активностью. Предсказывает IC_{50} или K_i для несинтезированных молекул.

7.4 Статья: Kovalenko et al. 2023 — клик-химия для ингибиторов D3R

Зачем: Найти ингибиторы рецептора дофамина D3 (мишень при шизофрении), проникающие через ГЭБ.

Как: In silico клик-реакция в RDKit — из 143 075 азидов получили 18 838 триазолов → фильтр Липинского → $\log BB \geq 0.3$ → докинг AutoDock Vina + iDock (корреляция $r = 0.96$) → 200 нс МД в AMBER с мембраной POPC:POPE:холестерин.

Результат: Хит ID 7000: аффинность -10.16 ккал/моль (референс этиклоприд -7.64); $\log BB = 0.34$ (этиклоприд -0.35). МД: $\Delta G_{lie} = -60.17$ vs -58.37 ккал/моль.

Вывод: Клик-реакция + $\log BB$ -фильтрация — рабочий подход для разработки ЦНС-активных антипсихотиков.

Билет 8. ПО для молекулярной динамики

8.1 Вопрос 1: ПО для молекулярной динамики и примеры применения

ПО	GPU	Лучшее для	Силовые поля	Особенности
GROMACS	Да	Белки, мембраны, ДНК	AMBER, CHARMM, GROMOS, OPLS	Быстрый, популярен в академии
AMBER	Да	Белок-лигандные комплексы	AMBER ff14SB/ff19SB, GAFF, Lipid21	ММ-PBSA прямо в пакете; лучший для фармы
NAMD	Да	Суперкомпьютеры, нанобиотех	CHARMM, AMBER	Визуализация через VMD
CHARMM	Частично	Нуклеиновые кислоты	CHARMM36	Широкий аналитический набор
Desmond (Schrödinger)	Да	Фармацевтика, HTS	OPLS4	60–80× быстрее CPU
OpenMM	Да	ML-потенциалы, Python	AMBER, CHARMM, OpenFF	Гибкость: плагин для нейросетевых силовых полей

8.2 Вопрос 2: Силовые поля в МД: типы, плюсы и минусы

Силовое поле — набор уравнений и параметров, описывающих взаимодействия между атомами: длины связей, углы, торсионы, электростатику (Кулон) и Ван-дер-Ваальс (Леннард-Джонс).

Основные семейства:

- **AMBER** (ff14SB, ff19SB) — для белков; GAFF — для органических лигандов; Lipid21 — для мембран
- **CHARMM36** — для нуклеиновых кислот и мембран
- **GROMOS** — открытый код, используется в GROMACS
- **OPLS-AA** — для фармацевтических молекул

Модели воды: TIP3P (быстрая, стандартная), OPC (точная, с ff19SB).

Плюсы: быстрые вычисления, системы до миллиона атомов, хорошо валидированы.

Минусы: не описывают разрыв/образование связей, могут давать артефакты.

8.3 Вопрос 3: Ключевые параметры МД для оценки белка

- **RMSD:**

$$RMSD = \sqrt{\frac{1}{N} \sum_{i=1}^N (r_i - r_{0i})^2}$$

Вышел на плато ($\sim 1-3 \text{ \AA}$) $\rightarrow$ система равновесна. Скачок $> 5 \text{ \AA}$ $\rightarrow$ нестабильность. RMSD лиганда $< 2 \text{ \AA}$ $\rightarrow$ докинг был правильным.

- **RMSF** — гибкость каждого аминокислотного остатка. Коррелирует с B-фактором кристаллографии.
- **R_g** (радиус вращения) — компактность. Растёт при разворачивании белка.
- **Водородные связи** — стабильность белок-лигандного комплекса.
- **MM-PBSA / MM-GBSA** — свободная энергия связывания (ΔG). Точнее докинга, но медленнее.

8.4 Статья: Ergodicity Breaking and Self-Destruction of Cancer Cells

Зачем: Проверить, может ли усиленный геномный хаос (хромотрипсис) приводить к самоуничтожению раковых клеток.

Как: Монте-Карло симуляция мутаций гена BCL2 на Python; стабильность мутанта — через Rosetta; докинг белок-белок — ZDOCK; эксперимент на рабдомиосаркоме крыс.

Что получили: При $\sim 10\%$ клеток с хромотрипсисом вероятность мутации BCL2 $\rightarrow$ 1. Мутант G5W дестабилизирован: $\Delta E_S = +4.11 \text{ REU}$ $\rightarrow$ апоптоз запускается.

Вывод: Индукция геномного хаоса — потенциальная противораковая стратегия.


Билет 9. Вычислительная синтетическая биология и QSAR

9.1 Вопрос 1: Вычислительная синтетическая биология и хемоинформатика

Синтетическая биология (SynBio) — проектирование новых биологических систем. Принцип: Design → Build → Test → Learn.

Пример пересечения — биосинтез артемизинина:

1. **Генеративная химия:** модель (VAE/диффузионная) предлагает SMILES целевого соединения.
2. **Ретросинтез** (ASKCOS, AiZynthFinder): рекурсивно разбивает SMILES на прекурсоры:



3. **Маппинг на ферменты:** KEGG/Rhea — ADS и CYP71AV1 найдены в полыни.
4. **Реализация (SynBio):** гены ADS и CYP71AV1 встраивают в геном *S. cerevisiae*.

Результат: >100 мг/л артемизининовой кислоты (Keasling lab, 2006) → промышленное производство (Sanofi).

9.2 Вопрос 2: Теория графов в синтетической биологии и хемоинформатике

Граф $G = (V, E)$ — множество вершин V и рёбер E .

В хемоинформатике: молекула → **молекулярный граф**: атомы = вершины, связи = рёбра. Позволяет применять алгоритмы теории графов.

Алгоритм Моргана (ECFP):

1. Радиус 0: каждому атому — атомный номер (C→6, N→7, O→8)
2. Радиус 1: суммируются значения соседей → кодирует ближайшее окружение
3. Радиус R: повторяем → ECFP4 (радиус 2), ECFP6 (радиус 3)
4. Каждое число хэшируется → бит в векторе длиной 2048

Коэффициент Танимото:

$$T(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

$T = 1.0$ → идентичны, $T > 0.85$ → похожи, $T = 0.0$ → ничего общего.

В синтетической биологии:

- Белок-белковые сети (PPI): белки = вершины, взаимодействия = рёбра
- Метаболические сети: метаболиты = вершины, ферменты = рёбра
- Граф де Брёйна — основа сборки NGS-данных (Velvet, SPAdes)

9.3 Вопрос 3: QSAR и QSPR — концепция и типы

QSAR (Quantitative Structure–Activity Relationship) — связывает структуру молекулы с её биологической активностью. **QSPR** (Quantitative Structure–Property Relationship) — то же, но целевое значение — физ.-хим. свойство.

Общая формула:

$$Y = f(D_1, D_2, \dots, D_n)$$

где Y — активность/свойство, D_i — дескрипторы молекулы.

Домен применимости: модель надёжна только для молекул, похожих на обучающую выборку.

Тип	Метод	Плюсы	Минусы
Линейные	MLR, PLS	Интерпретируемы	Не улавливают
ML-методы	RF, XGBoost, SVM, нейросети	малые данные	нелинейность
		Высокая точность, нелинейность	Нужно много данных, «чёрный ящик»
3D-QSAR	CoMFA, CoMSIA	Учитывают 3D-форму и поля	Требуют выравнивания структур
Фингерпринтовые	ECFP, MACCS	Быстро, легко	Теряют информацию о геометрии

Конкретные QSPR-примеры:

- Метод Кларка: $\log BB = 0.152 \cdot \log P - 0.0148 \cdot TPSA + 0.139$
- XGBoost для классификации ГЭБ: ROC-AUC = 0.96 (NeuroClick)

9.4 Статья: NeuroClick (Isakova et al., 2024)

Зачем: разработать программу для автоматической генерации библиотек drug-like молекул через in silico click-реакцию с фильтром ГЭБ.

Как делали: Python/RDKit с GUI имитирует азид-алкиновое циклоприсоединение (CuAAC) и фильтрует продукты по правилу Липинского и уравнениям QSPR Clark/Rishton (порог $\log BB \geq 0.3$).

Что получили: из 143 075 азидов + 1 алкин сгенерировано 284 770 триазолов за ~17 мин (~9000 молекул/мин); после фильтрации осталось **1056 кандидатов**, 95% из которых не являются субстратами P-гр.

Вывод: NeuroClick объединяет click-химию и хемоинформатику в одном инструменте.

Билет 10. Монте-Карло, Drug Repurposing, базы данных

10.1 Вопрос 1: Монте-Карло и имитация отжига

Оба метода — стохастические алгоритмы оптимизации. Оба основаны на **критерии Метрополиса**: если новая конфигурация энергетически выгоднее — принять; если нет — принять с вероятностью $P = \exp(-\Delta E/kT)$.

Монте-Карло (МК): работает при постоянной температуре. Прост в реализации, но может застрять в локальном минимуме.

Имитация отжига (SA): расширение МК, где Т постепенно снижается ($T = T_0 \cdot \alpha^{\text{шаг}}$). Высокая Т → широкий поиск; низкая Т → «замерзание» в минимуме. Лучше находит оптимальное решение, но медленнее.

Применение: молекулярный докинг (AutoDock), оценка стабильности мутантов белка (Rosetta Monte Carlo), конформационный поиск молекул.

10.2 Вопрос 2: Drug repurposing

Drug repurposing — поиск новых показаний для уже одобренных препаратов.

Почему перспективно: традиционная разработка — 10–15 лет и >1 млрд долларов; одобренный препарат уже прошёл фазы токсикологии.

Пайплайн:

1. Новая мишень определена (например, протеаза вируса)
2. Скрининг одобренных препаратов из DrugBank (~10 000) — докинг ко всем сразу
3. Отбор по скорингу — топ-10–50 препаратов по ΔG
4. QSAR/similarity-анализ — ищут аналоги хитов в ChEMBL
5. Проверка ADME — новые дозы/пути введения
6. МД-валидация — стабильность комплекса с новой мишенью
7. In vitro/in vivo — экспериментальная проверка

Пример: лопинавир против COVID-19

Секвенирование SARS-CoV-2 → 3CL-протеаза структурно похожа на ВИЧ-протеазу → лопинавир (одобрен против ВИЧ) → докинг к 3CL-протеазе (PDB: 6LU7): $\Delta G \approx -7.. -8$ ккал/моль → клинические испытания. Гипотеза сгенерирована за недели вместо лет.

10.3 Вопрос 3: Химические базы данных

База	Что содержит
PDB	>200 000 рентгеноструктурных и NMR-структур; формат .pdb; основа докинга
ZINC	~40 млн коммерчески доступных drug-like молекул в 3D
ChEMBL	Структуры + IC ₅₀ /Ki из литературы
PubChem	>100 млн соединений + биоассаи
DrugBank	Структуры, мишени, фармакокинетика; ключевая для drug repurposing
BindingDB	Экспериментальные константы связывания
dbSNP	Все SNP человека

База	Что содержит
UniProt	Последовательности белков
COSMIC	Соматические мутации в опухолях
SciFinder	89 млн соединений + патенты

10.4 Статья: Dutta et al. 2024 — SNP в hnRNPA2/B1

Зачем: Белок hnRNPA2/B1 гиперэкспрессирован при раке — авторы оценили, как мутации F66L и E92K влияют на его стабильность и связывание с камптотецином (CPT).

Как делали: SNP отобраны из NCBI-SNP/UniProt; стабильность через Rosetta (Monte Carlo) и Molsoft; докинг — AutoDock4; валидация — 44 239 образцов опухолей COSMIC.

Что получили: Мутация E92K максимально дестабилизирует белок ($\Delta E_{ros} = +21.4$ REU против +14.18 у F66L), снижает сродство к РНК (с -18.52 до -15.42 ккал/моль) и к CPT (с -9.55 до -8.23).

Вывод: hnRNPA2/B1 — перспективная онкомишень; E92K снижает эффективность камптотецина.

Билет 11. Молекулярные дескрипторы и химические форматы

11.1 Вопрос 1: Молекулярный дескриптор — что это и какие важны для ГЭБ?

Молекулярный дескриптор — число, описывающее свойство молекулы для математического анализа. По уровню детализации:

- **1D** — из формулы: MW, число H-доноров (HBD), H-акцепторов (HBA)
- **2D** — из графа структуры: logP, PSA/TPSA, топологические индексы Винера и Рандика, фингерпринты (ECFP, MACCS)
- **3D** — из координат атомов: объём молекулы, SASA, энтропия Вороного (VE)

Для ГЭБ критичны: $PSA < 90 \text{ \AA}^2$, $\log P \leq 5$, $MW < 500 \text{ Da}$, $HBD \leq 3$, logBB. Расчёт — библиотека RDKit.

11.2 Вопрос 2: Типичные химические форматы в хемоинформатике

Формат	Назначение
SMILES	Строка символов для малых молекул (бензол = c1ccccc1). Компактен, без 3D.
SDF/MDL	Файл со структурой + активностью (IC ₅₀ , Ki). Стандарт для библиотек соединений.
MOL2	Содержит заряды атомов и типы связей; используется в докинге.
InChI/InChIKey	Уникальный идентификатор IUPAC; InChIKey — 27 символов для поиска в базах.
PDB	Для белков и нуклеиновых кислот (>200 000 структур).
PDBQT	PDB + заряды + параметры силового поля. Формат AutoDock для докинга.
FASTA	Аминокислотные и нуклеотидные последовательности.
GRO/TOP	Формат GROMACS для МД-симуляций.

Конвертация — OpenBabel (>100 форматов).

11.3 Вопрос 3: Основные дескрипторы в QSAR/QSPR

- **logP** — главный показатель жирорастворимости; чем выше, тем лучше проникает через мембраны
- **PSA/TPSA** — предиктор всасывания и прохождения ГЭБ
- **MW, HBD, HBA** — правило Липинского
- **Топологические индексы:** Wiener (пути в графе), Randić (разветвлённость)

- **Фингерпринты ECFP/Morgan** — бинарные векторы подструктур для similarity search
- **Энтропия Вороного (VE)** — 3D-дескриптор асимметрии; чем выше VE, тем активнее лиганд ($r^2 = 0.94$ на протеазе SARS-CoV-2)

11.4 Статья: Вороной-энтропия как дескриптор лиганд-белок взаимодействий

Зачем: Проверить, можно ли энтропию Вороного использовать для предсказания связывания лигандов с белками.

Как делали: 1144 лиганда к Mpro SARS-CoV-2 из BindingDB (формат SDF). Для каждого через RDKit из SMILES строили диаграмму Вороного и считали:

$$S_v = - \sum_n P_n \cdot \ln(P_n), \quad P_n = \frac{\text{число полигонов с } n \text{ сторонами}}{\text{всего полигонов}}$$

Что получили: Сильная линейная корреляция: $IC_{50} = -274.9 \cdot S_v + 613 \text{ нМ}$, $r^2 = 0.94$, $p = 0.0003$. Шенноновская энтропия по SMILES не показала значимой корреляции ($p > 0.05$).

Вывод: Пространственная асимметрия молекулы (VE) определяет аффинность к рецептору.

Билет 12. Сворачивание белка и секвенирование

12.1 Вопрос 1: Сворачивание белка и его значение для хемоинформатики

Protein folding — процесс принятия линейной аминокислотной цепочкой уникальной 3D-формы.

Иерархия структуры:

1. **Первичная** — линейная последовательность аминокислот
2. **Вторичная** — α -спирали и β -листы (водородные связи NH и C=O остова)
3. **Третичная** — полная 3D-конформация одной цепи (гидрофобный коллапс)
4. **Четвертичная** — комплекс из нескольких цепей (пример: гемоглобин — 4 цепи)

Парадокс Левинтала: перебор всех конформаций белка из 100 аминокислот занял бы дольше возраста Вселенной. Решение — иерархическое сворачивание через промежуточные вторичные структуры.

Ключевые инструменты:

- **AlphaFold2** — машинное обучение (Evoformer + MSA), медианный RMSD 0.56 Å
- **Rosetta** — метод Монте-Карло, RMSD ~ 2.6 Å
- **МД (AMBER/GROMACS)** — медленно, но отслеживает переходные состояния

12.2 Вопрос 2: ПЦР и in silico методы; сайт-направленный мутагенез

ПЦР — амплификация нужного фрагмента ДНК. Каждый цикл (20–40 повторений):

1. **Денатурация** (94–98°C) — двойная спираль ДНК расходится
2. **Отжиг** (50–65°C) — праймеры прикрепляются к матрице
3. **Элонгация** (72°C) — полимераза достраивает цепь в направлении 5'→3'

После N циклов: 2^N копий (за 30 циклов из 1 молекулы $\rightarrow \sim 10^9$ копий).

In silico инструменты: APE (редактор плазмид), Geneious (BLAST, выравнивание), Primer3/NCBI Primer-BLAST (дизайн праймеров), SnapGene (симуляция клонирования).

Сайт-направленный мутагенез:

1. Мутагенный праймер + ПЦР $\rightarrow$ плазида с мутацией
2. Обработка ферментом DpnI — разрезает исходную метилированную ДНК
3. Трансформация в бактерии $\rightarrow$ подтверждение секвенированием

Вычислительный аналог: FoldX ($\Delta\Delta G$: $\Delta\Delta G > 0 \rightarrow$ белок дестабилизируется), Rosetta ddG, PyMOL mutagenesis wizard.

12.3 Вопрос 3: Методы секвенирования; анализ экспрессии генов

SNP (Single Nucleotide Polymorphism) — замена одного нуклеотида в ДНК. Патогенность предсказывают MutPred2, PolyPhen-2, PROVEAN.

Поколение	Метод	Точность	Применение
Сэнгер (I)	Капиллярный электрофорез	>99.9%	Проверка мутаций, до 900 нуклеотидов

Поколение	Метод	Точность	Применение
NGS/Illumina (II)	Миллионы фрагментов параллельно	>99%	Полногеномное секвенирование, RNA-seq
Напорное (III)	Пора в мембране	~85–95%	Риды >10 000 нт, портативное

Affymetrix GeneChip: РНК → меченая кРНК → гибридизация на чип → лазерное сканирование → уровень экспрессии генов. Сейчас вытесняется RNA-seq.

12.4 Статья: Топологический биоскейлинг как мера сворачивания белков

Зачем: Создать быстрый метод оценки стадии сворачивания без медленных МД.

Как делали: МД-симуляция мини-белка Trp-cage (20 аа, PDB: 1L2Y) в AMBER (50 нс, 325K); отслеживали радиус инерции R_g и показатель скейлинга α (компактность: $\alpha = 1$ — вытянутая цепь, $\alpha = 0.33$ — глобуль).

Что получили: R_g снизился с 21.25 до 6.97 Å, фрактальная размерность $D = 1/\alpha$ выросла с 1 до 1.92. AlphaFold2 предсказал конечную структуру с RMSD = 0.56 Å.

Вывод: Показатели α и D — быстрые дескрипторы стадии фолдинга.

Билет 13. Моделирование реакций и алгоритмы фолдинга

13.1 Вопрос 1: Моделирование химических реакций in silico

Структурный уровень — SMARTS: Реакция кодируется как SMARTS-паттерн — правило преобразования связей: реакционные центры + что уходит + что образуется. Алгоритм применяет это правило ко всей библиотеке молекул автоматически.

Пример — click-реакция (CuAAC): азид + алкин $\rightarrow$ 1,2,3-триазол. NeuroClick реализует это через SMARTS $\rightarrow$ генерирует до 10 000 продуктов/мин $\rightarrow$ фильтрует по правилу Липинского и ГЭБ-проницаемости.

Обратная задача — ретросинтез: От продукта $\rightarrow$ к стартовым реагентам. Алгоритмы: AiZynthFinder, ASKCOS. Базы: Reaxys, CAS SciFinder.

Энергетический уровень — квантовая химия: Для понимания механизма реакции (переходные состояния, барьеры активации) используют DFT. Применяется к отдельным молекулам, не к библиотекам.

13.2 Вопрос 2: Хемоинформатика в генераторах химических реакций

Генератор реакций = химические правила (SMARTS) + хемоинформатические инструменты + фильтрация продуктов.

NeuroClick — Python/RDKit программа:

1. **Вход** — два файла SMILES: азиды и алкины
2. **Реакция** — SMARTS-алгоритм имитирует CuAAC ([3+2] циклоприсоединение) $\rightarrow$ 1,4-изомер 1,2,3-триазола; скорость ~ 9000 молекул/мин
3. **Фильтр 1: правило Липинского** — $MW \leq 500$, $\log P \leq 5$, $HBD \leq 5$, $HBA \leq 10$
4. **Фильтр 2: ГЭБ-проницаемость** — уравнения QSPR Clark/Rishton, порог $\log BB \geq 0.3$
5. **Фильтр 3: P-gr** — 95% кандидатов — не субстраты MDR-транспортёра
6. **Выход** — файл SMILES + ADME-дескрипторы

Результат на реальных данных: 143 075 азидов $\times$ 1 алкин $\rightarrow$ 284 770 триазолов $\rightarrow$ 1056 кандидатов за ~ 17 мин.

13.3 Вопрос 3: Алгоритмы анализа молекулярного фолдинга

Проблема: прямое МД-моделирование фолдинга требует мс-симуляций.

AlphaFold2 (DeepMind, 2021):

- Вход: аминокислотная последовательность (FASTA)
- Архитектура: трансформер (Evoformer) + MSA (множественное выравнивание последовательностей)
- Выход: 3D-координаты + pLDDT (confidence score 0–100)
- Точность: медианный RMSD ~ 0.56 Å (CASP14), сопоставимо с рентгенографией

RoseTTAFold (Baker lab, 2021) — трёхтрековая нейросеть (последовательность + выравнивание + координаты), быстрее AlphaFold2, хуже по точности.

RetroFold (Shityakov, 2023):

- Наблюдение: разфолдинг (денатурация) — ~ 5 нс; фолдинг — мкс–мс

- Идея: применить логарифмическое преобразование к траектории разфолдинга $\rightarrow$ получить приближение фолдинга
- Результат: ошибка $< 4.1\%$ ($r^2 = 0.99$), затраты в **100× меньше**

Для нуклеиновых кислот: mfold/RNAfold — минимизация свободной энергии вторичной структуры.

13.4 Статья: RetroFold — асимметрия фолдинга белка

Зачем: Прямое МД-моделирование фолдинга требует ~ 800 нс. Авторы искали более дешёвый способ.

Как делали: Мини-белок Trp-cage (PDB: 1L2Y): МД фолдинга (325K, 800 нс) и разфолдинга (498K, 5 нс) в AMBER; к траектории разфолдинга применили логарифмическое преобразование.

Что получили: RetroFold воспроизводит траекторию фолдинга с ошибкой $< 4.1\%$ ($r^2 = 0.99$) при затратах в 100× меньше.

Вывод: Разфолдинг (быстрый, постоянная скорость) и фолдинг (медленный, экспоненциальное затухание) математически связаны — алгоритм назван по аналогии с ретро-синтезом.

Билет 14. ML/DL и конформационный поиск

14.1 Вопрос 1: ML/DL методы в хемоинформатике

Метод	Вход	Как работает	ПО	Пример
Random Forest	Дескрипторы/ESCF	Ансамбль деревьев; устойчив к шуму	RDKit sklearn	+ logBB, токсичность
XGBoost	Дескрипторы/fingerprints	Градиентный бустинг	xgboost sklearn	+ AUC = 0.96 для ГЭБ
ANN	Дескрипторы	Слои: вход → скрытые → выход	PyTorch/Keras	Регрессия logBB
GNN	Молекулярный граф	Message passing: атом агрегирует от соседей	PyTorch Geometric	EquiBind
CNN (GNINA)	3D-воксели	CNN «видит» карман как изображение	GNINA (github)	+5% vs AutoDock Vina
Диффузионная (DiffDock)	Граф + 3D	Запумляет позу → учится обращать	DiffDock (MIT)	38% поз RMSD <2 Å
VAE/GAN	SMILES/граф	Кодирует → декодирует новые структуры	GuacaMol, REINVENT	De novo генерация

Python-библиотеки: RDKit, DeepChem, PyTorch Geometric, scikit-learn.

14.2 Вопрос 2: ML/DL vs классические методы

Классические методы:

- Поисковые — GA (AutoDock Vina), MC: быстрые, не требуют обучающих данных
- Физические — форс-филды (MMFF94, AMBER): атомы как шары на пружинах; квантовая химия (DFT): самая точная

Преимущества ML/DL:

1. Мгновенное предсказание свойств для миллионов молекул
2. Генерация новых структур (VAE, GAN, диффузия)
3. Интеграция разнородных данных

Недостатки ML/DL:

1. Нужны большие наборы данных; при малой выборке — ненадёжны
2. «Чёрный ящик» — сложно объяснить причину активности
3. Генерируют стерические клэши
4. Плохо экстраполируют за пределы обучающих данных

14.3 Вопрос 3: Конформационный поиск, симметрия, тесселляция Вороного

Конформеры — разные пространственные формы одной молекулы. Методы поиска:

1. Систематический — перебор углов с шагом 60° ; точный, 6^n вариантов
2. Monte Carlo — случайные изменения + критерий Метрополиса
3. МД — конформеры из снимков траектории
4. Генетические алгоритмы — AutoDock Vina, до 32 вращаемых связей

Тесселляция Вороного — разбиение пространства: ячейка каждого атома содержит все точки, ближайšie именно к нему.

Применения в хемоинформатике:

- Дескриптор окружения атома — площадь/объём ячейки отражает «упакованность»
- Анализ белок-лигандных контактов — граница ячеек = контактная поверхность
- QSAR-дескриптор

Энтропия Вороного:

$$V_E = - \sum_i P_i \cdot \log(P_i), \quad P_i = \frac{S_i}{S_{total}}$$

$V_E = 0$ — абсолютно симметричная молекула; $V_E \rightarrow \max$ — максимально несимметричная.

14.4 Статья: α -Циклодекстриновый димер для доставки дофамина в мозг

Зачем: При болезни Паркинсона DA и L-DOPA плохо проникают через ГЭБ.

Как делали: 14 молекул (DA, L-DOPA, 12 Dopimid-производных) состыковали с α -CD-димером (полость $346 \text{ \AA}^3$) через AutoDock Vina; свойства рассчитали в PreADMET.

Что получили: Лучшие кандидаты — Dopimid 9–11 ($\Delta G = -7.4.. -7.6$ ккал/моль, $\log BB > 0$). Соединения 5–7 с этил-ацетатным остатком не вошли в полость ($\Delta G \approx -4.3$ ккал/моль). Дескриптор S_{MHP} коррелирует с константой связывания: $r^2 = 0.87$.

Вывод: α -CD-димер — рабочая наносистема доставки DA в ЦНС.

Билет 15. Хемоинформатика в материаловедении. Протокол МД

15.1 Вопрос 1: Хемоинформатика в материаловедении и супрамолекулярной химии

Материаловедение. МД применяется для изучения цитотоксичности наночастиц (графен, нанотрубки) и предсказания их поведения до эксперимента.

Наночастицы как носители лекарств. Фуллерены (C60, C70) и SWCNT — перспективны для доставки препаратов. Ключевой вопрос: распознаёт ли их Р-гр (транспортёр MDR)?

Супрамолекулярная химия. Циклодекстрины — конусообразные молекулы с гидрофобной полостью — образуют нековалентные комплексы «хозяин-гость». Три типа: α -CD (6 субъединиц), β -CD (7), γ -CD (8). Докинг подбирает оптимальный тип под лиганд.

15.2 Вопрос 2: Стандартный протокол молекулярной динамики

1. **Подготовка белка:** скачать PDB, PROCHECK ($\geq 90\%$ остатков в ядре), добавить водороды (pH 7.4), назначить протонационные состояния His/Asp/Glu, заряды ff14SB; лиганд — GAFF2, RESP-заряды
2. **Сольватация:** водный бокс TIP3P/OPC + ионы Na^+/Cl^- до 0.15 M
3. **Минимизация:** 500–5000 шагов steepest descent + сопряжённые градиенты
4. **Нагрев (NVT):** 0 K $\rightarrow$ 300 K за 100–200 пс
5. **Уравновешивание (NPT):** 1 атм, 300 K; 100 пс – 1 нс
6. **Продакшн:** 50–500 нс (стандарт 100–200 нс); сохранение каждые 1–10 пс
7. **Анализ:** RMSD (плато $< 3 \text{ \AA}$), RMSF, R_g , H-связи, MM-PBSA/MM-GBSA

Программы: AMBER, GROMACS, NAMD. Анализ: CPPTRAJ (AMBER), MDAnalysis (Python).

15.3 Вопрос 3: Стандартный протокол молекулярного докинга (AutoDock Vina)

1. **Подготовка белка:** PDB, PROCHECK, удалить воду/гетероатомы, добавить полярные водороды, заряды Гастайгера $\rightarrow$ формат **PDBQT**
2. **Подготовка лиганда:** SMILES $\rightarrow$ 3D (RDKit/OpenBabel), MMFF94, $\rightarrow$ PDBQT
3. **Grid box:** центр на активном сайте (FPocket/SiteMap), 20–30 $\text{\AA}$; exhaustiveness = 8 (стандарт), 32–64 для тщательного поиска
4. **Запуск:** AutoDock Vina выводит топ-9 поз с ΔG
5. **Анализ:** визуализация PyMOL/Chimera; взаимодействия PLIP/LigPlot+
6. **Валидация (обязательно!):** редокинг ко-кристаллизованного лиганда, критерий $\text{RMSD} < 2 \text{ \AA}$

15.4 Статья: Shityakov & Förster (2013) — Р-гр с фуллеренами и нанотрубкой

Зачем: Выяснить, являются ли углеродные наночастицы субстратами Р-гр (причина MDR).

Как делали: Докинг C20, C60, C70 и SWCNT (C168) к P-гр мыши (PDB: 3G60) тремя алгоритмами: ADVina, FastDock (PMF), PatchDock.

Что получили: C60 и C70 связываются с $\Delta G = -54.8$ и -56.9 кДж/моль (контроль -40.6) — субстраты P-гр. SWCNT: $\Delta G > 0$ — связывания нет. Остаточная площадь π - π стэкинга (A_{res}) коррелирует с аффинностью: $r^2 = 0.99$, $P < 0.0007$.

Вывод: SWCNT не распознаётся P-гр $\rightarrow$ перспективна как наноноситель при MDR.

Билет 16. ADME/ADMET

16.1 Вопрос 1: Концепция ADME/ADMET в хемоинформатике

Буква	Что	Описание
A	Absorption	Всасывание в ЖКТ. Критерий — правило Липинского: $MW < 500$ Da, $\text{LogP} < 5$, $\text{HBA} < 10$, $\text{HBD} < 5$
D	Distribution	Распределение по тканям. Для ЦНС-препаратов критично проникновение через ГЭБ
M	Metabolism	Разрушение ферментами печени CYP450. Влияет на период действия и образование токсичных продуктов
E	Excretion	Скорость выведения через почки или желчь
T	Toxicity	Острая токсичность (LD_{50}), поражение сердца (hERG-канал), печени, мутагенность

Основные инструменты: FAF-Drugs4, admetSAR, pkCSM, ProTox-II.

16.2 Вопрос 2: Молекулярные дескрипторы для расчёта ADME-свойств

Для всасывания: MW, LogP, HBA/HBD, tPSA.

Для ГЭБ-проницаемости:

- $\text{tPSA} < 90 \text{ \AA}^2 \rightarrow$ молекула хорошо проникает в мозг
- $\text{logBB} \geq 0.3 \rightarrow$ концентрация в мозге выше, чем в крови
- **BBB_P-Prob** (admetSAR) — вероятность пассивного проникновения, AUC модели = 0.952
- **LogPS** (pkCSM) $> -2 \rightarrow$ хорошая проницаемость

Для токсичности: Fsp3 (> 0.4 — хорошо), PAINS (фрагменты, дающие ложные биологические результаты), PhI (предиктор фосфолипидоза).

P-gp: admetSAR и pkCSM предсказывают, является ли молекула субстратом или ингибитором Р-гликопротеина.

16.3 Вопрос 3: Метод scaffold hopping в хемоинформатике

Scaffold hopping — замена химического ядра при сохранении биологической активности.

Типы по степени изменения:

1. Биоизостерическая замена — кольцо заменяется на похожее (бензол $\rightarrow$ пиридин)
2. Топологически эквивалентные скаффолды — структурно разные, но геометрически схожие
3. Фрагментный подход — молекула разбирается на фармакофорные фрагменты, под них ищется новое ядро

Плюсы: обход патентной защиты, улучшение ADME, снижение токсичности, доступ к новым структурным классам.

Минусы: новое ядро может изменить 3D-геометрию и потерять активность; высокая вычислительная стоимость; сложный синтез.

16.4 Статья: Tamaian et al. (2023) — Новые антипсихотики с улучшенным профилем

Зачем: разработать более безопасные антипсихотики с лучшим проникновением через ГЭБ.

Как делали: из 5 известных антипсихотиков получили 15 скаффолдов, объединили с 7 строительными блоками (SmiLib) → 315 молекул → ADME-Tox фильтрация (FAF-Drugs4, admetSAR, pkCSM) → докинг (AutoDock Vina) к 6 рецепторам серотонина и дофамина.

Что получили: лучший кандидат **HAL_1.1_3_3_3**: аффинность к $5\text{-HT}_{2A} = -11.8$ ккал/моль (исходный HAL: -9.5); $LD_{50} = 800$ мг/кг (HAL: 71 мг/кг) — в 11 раз безопаснее.

Вывод: scaffold hopping с ADME-Tox фильтрацией позволяет создавать менее токсичные и более эффективные препараты.

Билет 17. Ретровирусные протеазы и фингерпринты

17.1 Вопрос 1: Почему ретровирусные протеазы и циклодекстрины — предпочтительные модельные системы?

ВИЧ-протеаза используется как модель белок-лигандного взаимодействия по трём причинам:

1. Структура хорошо изучена — сотни кристаллических структур в PDB с высоким разрешением ($\sim 2 \text{ \AA}$)
2. C2-симметрия (два одинаковых мономера) — удобно для тестирования алгоритмов докинга
3. Известен референсный ингибитор Индинавир — есть эталон для сравнения расчётов

Циклодекстрины — циклические молекулы из сахарных звеньев с гидрофобной полостью. β -циклодекстрин (7 звеньев) — наиболее удобен: полость чётко определена геометрически, хорошо изучена экспериментально. Обе системы — **общепринятые бенчмарки** для валидации методов докинга и МД.

17.2 Вопрос 2: Молекулярные фингерпринты в хемоинформатике

Молекулярный фингерпринт — цифровой «код» молекулы в виде строки 0 и 1, где каждый бит означает наличие или отсутствие определённого структурного фрагмента.

Тип	Описание
ECFP (Extended Connectivity Fingerprint)	Круговые; кодируют атомное окружение на заданном радиусе; ECFP4 — наиболее популярны
MACCS keys	166 фиксированных фрагментов; простые и интерпретируемые
Avalon / Daylight / RDKit	Топологические: кодируют пути между атомами
Фрагментные (RDKit + XGBoost)	AUC ROC ≈ 0.96 для предсказания проницаемости через ГЭБ

Главная метрика сходства — **коэффициент Танимото**:

$$T(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

17.3 Вопрос 3: Чем фингерпринты отличаются от молекулярных дескрипторов?

Молекулярный скриптор	де-	Фингерпринт
Числовое значение физ.-хим. свойства	физ.-	Специальный подтип дескриптора — битовый вектор
Непрерывный (LogP 2.3)	(LogP =	Дискретный (0 или 1)
Кодирует свойства	физические	Кодирует структурные фрагменты
Используется в QSAR и регрессии	и	Используется в поиске сходства и классификации
Интерпретируем		Часто «чёрный ящик»

На практике лучшие модели используют оба типа вместе.

17.4 Статья: Shityakov et al. (2020) — Виртуальное секвенирование ДНК-плазмид

Зачем: Проверить, может ли алгоритм имитировать shotgun-секвенирование до реального эксперимента.

Как делали: Три плазмиды (2319–4886 п.н.) «секвенировали» виртуально (алгоритм Sequencer + TIGR Assembler) при длинах фрагментов 100, 400, 800 нт и покрытии 1–9; затем валидировали ПЦР.

Что получили: При длине ≥ 400 нт и покрытии ≥ 4 — один непрерывный контиг, зависимость линейная ($r^2 = 0.99$). ПЦР подтвердила расчёты: $r^2 = 0.92$, $p = 0.012$.

Вывод: Алгоритм работает как дешёвый инструмент контроля качества и планирования реального секвенирования.

Связь с вопросами билета

Статья иллюстрирует ключевой принцип курса: вычислительная модель предшествует эксперименту — та же логика, что в молекулярном докинге и QSAR.

Краткая таблица: ключевые статьи

Статья	Ключевой вывод
Shityakov & Dandekar 2010	Из 1300 производных индинавира → 1 хит (MW=494, 10 Н-связей vs 9 у IDV)
PSA и ГЭБ	3D-PSA лучшая ($R^2=0.92$), TPSA компромисс ($R^2=0.85$); порог PSA < 60 Å ²
Shityakov & Förster 2014 (BBB-ChT)	Гомологичная модель + докинг: $r^2=0.88$, AUC=0.82; молекулы <20 атомов → ложноотрицательный
Shityakov et al. 2021 (Альцгеймер)	Скаффолд-поиск → докинг → МД: менадион бисульфит ($\Delta G=-7.11$) лучше трамипросата (-6.19)
NeuroClick 2024	143 075 азидов → 1056 кандидатов за 17 мин; 95% — не субстраты Р-гр
Kovalenko et al. 2023 (D3R)	Клик-химия + logBB-фильтрация: хит ID7000, $\Delta G=-10.16$ (vs -7.64), logBB=0.34
Fareed 2022 (DEFB1)	SNP T58S и Y35C разрушают сайт PIP2 → маркеры восприимчивости к инфекциям
Ergodicity / BCL2 (пак)	Индукция хромотрипсиса → мутация BCL2 G5W → дестабилизация → апоптоз
Dutta et al. 2024 (hnRNPA2/B1)	E92K максимально дестабилизирует ($\Delta E_{ros}=+21.4$ REU), снижает аффинность к CPT
Shityakov & Förster 2013 (Р-гр/нанотрубки)	SWCNT не субстрат Р-гр ($\Delta G > 0$); A_{res} коррелирует с аффинностью $r^2=0.99$
Tamaian et al. 2023 (антипсихотики)	HAL_1.1_3_3_3: аффинность к 5-НТ _{2A} = -11.8 (vs -9.5), LD50=800 мг/кг (vs 71)
Вороной-энтропия (Mpro)	$IC_{50} = -274.9 \cdot V_E + 613$ нМ, $r^2=0.94$
RetroFold 2023	Разфолдинг (5 нс) → фолдинг через логарифм. преобразование; ошибка <4.1%, в 100× дешевле
α -CD + допамин (Паркинсон)	Dopimid 9–11: $\Delta G=-7.4..-7.6$, logBB>0; S_{MHP} коррелирует с K_{bind} ($r^2=0.87$)
Shityakov 2020 (ДНК-плазмиды)	Виртуальное секвенирование: длина ≥ 400 нт + покрытие ≥ 4 → единый контиг; $r^2=0.99$

Главные формулы

Коэффициент Танимото:
$$T(A, B) = \frac{|A \cap B|}{|A \cup B|} \quad (1)$$

$\log BB$ (Кларк):
$$\log BB = 0.152 \cdot \log P - 0.0148 \cdot TPSA + 0.139 \quad (2)$$

RMSD:
$$RMSD = \sqrt{\frac{1}{N} \sum_{i=1}^N (r_i - r_{0i})^2} \quad (3)$$

Критерий Метрополиса:
$$P(\text{принять}) = \exp\left(\frac{-\Delta E}{kT}\right) \quad (4)$$

Энтропия Вороного:
$$V_E = - \sum_i P_i \cdot \ln(P_i) \quad (5)$$

Уравнение движения (МД):
$$r(t + dt) = r(t) + v \cdot dt \quad (6)$$

Вороной-QSAR (Mpro):
$$IC_{50} = -274.9 \cdot V_E + 613 \text{ нМ} \quad (7)$$

G хорошего связывания:
$$\Delta G < -8 \text{ ккал/моль} \quad (8)$$

Удачи на экзамене!